

Q&A — BRIEF

Bidaw 예상 질문 10선 (간략판)

발표 직전 빠른 점검

Bidaw — FAST '26 paper seminar 보조자료

Bidaw: Enhancing Key-Value Caching for Interactive LLM Serving via Bidirectional Computation-
Storage Awareness

Hu et al., FAST '26

전체 30문항 중 발표 방어에 가장 자주 쓸 핵심 10개. 입으로 답할 수 있어야 한다.

Q1. **Weighted** reuse distance가 그냥 거리(횟수)랑 어떻게 다른가?

횟수가 아니라 **byte 단위**다. 두 access 사이에 끼어든 **다른 KV의 총 byte 합**. Cache 압력은 byte로 표현해야 perf layer 크기와 직접 비교된다 ("80 % > 200 GB").

Q2. 단순 prefetch / overlap이 안 되는 이유?

GPU iteration $\approx$ 수십 ms, capacity-layer I/O $\approx$ 수백 ms. 한 iteration overlap으론 **일부만** 가려진다. 결국 **큐 자체**를 재구성해야 한다.

Q3. disk-HRRN이 원래 HRRN과 다른 점은?

Service time을 **KV size**로 대체. 가정: capacity-layer I/O 시간 $\approx$ KV size / SSD bandwidth. 식은 $R = 1 + \text{waiting} / \text{size}$ 로 동일.

Q4. 답변 길이 $\leftrightarrow$ reuse distance $p = 0.94-0.98$ — 무엇과 무엇의 상관인가?

답변 길이 vs reuse distance의 **하한**. 평균이 아니다. 답변이 길수록 사용자 사고 시간이 길고, 그 사이 다른 사용자 KV가 **최소** 그만큼 끼어든다.

Q5. Belady's algorithm은 미래를 알아야 하는데 ghost cache에서 왜 가능한가?

Ghost cache는 **지나간 trace**만 가지고 있다. 그 trace에 대해선 미래(=현재)를 이미 알고 있으므로 Belady가 사후적으로 시뮬레이션 가능. 그 측정값을 다음 access의 hit 확률 추정치로 사용.

Q6. Equation 2의 세 항을 설명하라.

$\text{prob_small} \cdot 1.0 + \text{prob_extreme} \cdot 0.0 + \sum_i \text{prob_promising}(i) \cdot \text{hit_promising}(i)$. Small region(< perf layer 크기) $\rightarrow$ hit 확률 1, extreme(> 440 GB) $\rightarrow$ 0, promising은 bucket별 **Optimal hit rate** $\times$ 그 bucket에 떨어질 확률. 가장 낮은 potential의 KV를 evict.

Q7. Tensor 6가 KV tensor보다 좋은 수치적 근거?

Cost efficiency (saved compute / required space): Tensor 6 = **51 GFLOPs/MB**, KV = 30.5. 같은 host DRAM 공간에서 $1.67 \times$ compute를 절약.

Q8. GQA에서 Mechanism 3을 비활성화하는 이유?

GQA는 query head들이 K,V를 공유 $\rightarrow$ KV tensor 자체가 $1/g$ 작아진다. 변환 비용은 그대로라서 cost-efficiency 우위가 사라진다. $\rightarrow$ KV 캐시가 더 이득.

Q9. ShareGPT에서 효과가 약해지는 이유?

ShareGPT는 사용자 timestamp가 없어 **Poisson 시뮬**로 시간 보간. 이 시뮬은 **답변 길이 $\leftrightarrow$ 사고 시간**의 상관을 깬다. 따라서 compute $\rightarrow$ storage 신호의 정확도가 떨어져 eviction 효과가 약화된다고 (Scheduling은 영향 적음).

Q10. Bidaw가 **lossless**인가? 답변 정확도가 바뀌나?

답변 정확도는 **그대로**. Scheduler는 user1·user2의 처리 **순서**만 바꾸고 각 요청 안의 LLM 출력은 그대로다. 압축/양자화류와 정반대 입장.

답변 자세 (한 줄)

- 모르는 부분은 **모른다고**. ("논문이 명시하지 않았습니다.")
- 한계는 **미리 인정** — 신뢰가 올라간다.
- 핵심 숫자($3.58 \times / 1.83 \times / 22.4 / 0.94 / 51$ vs 30.5)는 **막힘 없이** 나와야 한다.